

기계학습 (Machine Learning)

- Introduction

정보통신공학과
Prof. Jinkyu Kang



What is this course for?

- 본 교과목은
 - 1) 기계학습 분야에서 요구하는 수학을 이해하고
 - 2) 기계학습의 대표적인 알고리즘들인 지도 학습(회귀 및 분류 등), 비지도 학습(군집화 등), 강화 학습, 및 준지도 학습에 관한 개념과 특성을 이해하며
 - 3) 주어진 문제에 가장 적합한 기계 학습 알고리즘을 선택할 수 있도록 기계학습의 기반이 되는 이론적인 내용과 예제들을 이론적으로 다룰 예정입니다 ☺
- 주 교과 내용:
 - 기계학습의 기본인 데이터와 특징 공간이라는 개념과 함께 기계학습 전반을 소개
 - 기계학습에서 수학이 왜 필요한지 어떻게 활용하는지 이해 (선형대수, 확률과 통계, 최적화 설명)
 - 기계학습의 기본적 알고리즘들인 지도 학습, 비지도 학습, 강화 학습 및 준지도 학습 방법의 개념과 이론을 이해하고 예제를 통해 활용 범위와 방법 학습
- 수업진행방법
 - 대면 수업 및 LMS/이메일 이용한 질문과 답변.





Who will help you learning?

- Instructor: 강진규 (Jinkyu Kang)
- Office: Y5624
 - Email: jkkang@mju.ac.kr
- Office Hour:
 - 화/목요일, 4:00 PM ~ 5:00 PM
 - Best to make an appointment via sending e-mail/LMS
- Teaching Assistant: 이재호 (Y5619)



Which books to use?

- Textbook 1: 기계 학습
(저자: 오일석)
- Textbook 2: 핸드온 머신러닝
(저자: 오렐리앙 제롱)
- References:
 - Many other resources available in the library, internet, etc.



Which topics we cover? (1/2)

- 기계학습 소개
- 기계학습과 수학
- 지도 학습 (Supervised learning)
 - 통계적 분류
 - 신경망 및 퍼셉트론
 - SVM (Support Vector Machine)
 - 질적 분류 및 결정 트리
- 특징 추출 및 선택
- 비지도 학습 (Unsupervised learning)
 - 군집화
- 준지도 학습 & 강화 학습 ((Semi-supervised & Reinforcement learning)



Which topics we cover? (2/2)

주제 및 수업 핵심내용		학습자료 및 과제
1주차	기계학습 소개 및 이해	
2주차	기계학습과 수학 - 1/2	
3주차	기계학습과 수학 - 2/2	
4주차	통계적 분류 (Classification) - 1/2	1차 평가 과제
5주차	통계적 분류 (Classification) - 2/2	
6주차	신경망 (Neural network) 및 퍼셉트론 (Perceptron)	
7주차	Support Vector Machine (SVM)	
8주차	질적 분류 및 결정 트리 (Decision tree)	2차 평가 과제
9주차	중간 고사	
10주차	특징 추출 (Feature extraction)	
11주차	특징 선택 (Feature selection)	
12주차	비지도 학습 (Unsupervised learning) - 1/2	
13주차	비지도 학습 (Unsupervised learning) - 2/2	3차 평가 과제
14주차	준지도 학습 (Semi-supervised learning) 및 강화 학습 (Reinforcement learning)	
15주차	기말 고사	



When do we learn?

- Lecture
 - 대면 수업
 - Lecture note at LMS
- Others
 - Office hour/이메일을 이용한 질문과 답변



What's my final **Grade** based on?

- 출석: 10%
- 과제물/보고서: 15%
- 중간고사: 35%
- 기말고사: 40%



이번주 수업의 목차

- 기계학습 소개

- 인공지능, 머신러닝 그리고 딥러닝
- 기계 학습이란?
- 특징 공간에 대한 이해
- 데이터에 대한 이해
- 간단한 기계 학습의 예
- 모델 선택
- 규제
- 기계 학습 유형



기계학습 소개 |

인공지능, 머신러닝 그리고 딥러닝

Artificial Intelligence

인공지능

사고나 학습 등 인간이 가진
지적 능력을 컴퓨터를 통해
구현하는 기술



Machine Learning

머신러닝


컴퓨터가 스스로 학습하여
인공지능의 성능을
향상 시키는 기술 방법



Deep Learning

딥러닝

인간의 뉴런과 비슷한
인공신경망 방식으로
정보를 처리



기계학습 소개

- 사람의 학습

- 수학, 과학, 역사뿐 아니라 수영, 자전거 타기 등



- 기계 학습

- 그렇다면 기계도 학습할 수 있을까?
- 경험을 통해 점점 성능이 좋아지는 기계를 만들 수 있을까?
- 이 과목은 이 질문에 대한 답을 찾아가는 길

기계 학습이란?

- 기계 학습의 정의
- 지식기반 방식에서 기계 학습으로의 대전환
- 기계 학습 개념
- 사람의 학습과 기계 학습



기계학습이란? | 기계 학습의 정의

- 학습이란? <표준국어대사전>

“경험의 결과로 나타나는, 비교적 지속적인 행동의 변화나 그 잠재력의 변화. 또는 지식을 습득하는 과정[국립국어원2017]”

- 기계 학습이란?

- 인공지능 초창기 사무엘의 정의

“Programming computers to learn from experience should eventually eliminate the need for much of this detailed programming effort. 컴퓨터가 경험을 통해 학습할 수 있도록 프로그래밍할 수 있다면, 세세하게 프로그래밍해야 하는 번거로움에서 벗어날 수 있다[Samuel1959].”



기계학습이란? | 기계 학습의 정의

- 기계 학습이란?
 - 현대적 정의

“A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E . 어떤 컴퓨터 프로그램이 T 라는 작업을 수행한다. 이 프로그램의 성능을 P 라는 척도로 평가했을 때 경험 E 를 통해 성능이 개선된다면 이 프로그램은 학습을 한다고 말할 수 있다[Mitchell1997(2쪽)].”

“Programming computers to optimize a performance criterion using example data or past experience 사례 데이터, 즉 과거 경험을 이용하여 성능 기준을 최적화하도록 프로그래밍하는 작업[Alpaydin2010]”

“Computational methods using experience to improve performance or to make accurate predictions 성능을 개선하거나 정확하게 예측하기 위해 경험을 이용하는 계산학 방법들[Mohri2012]”



기계학습이란? |

지식기반 방식에서 기계 학습으로의 대전환

- 인공지능의 탄생
 - 컴퓨터의 뛰어난 능력
 - 사람이 어려워하는 일을 아주 쉽게 함
 - $80932.46789076 * 0.39001324$ 와 같은 곱셈을 고속으로 수행(현재는 초당 수십억개)
 - 복잡한 함수의 미분과 적분 척척
 - 컴퓨터에 대한 기대감 (컴퓨터의 능력 과신)
 - 사람이 쉽게 하는 일, 예를 들어 고양이/개 구별하는 일도 잘 하지 않을까
 - 1950년대에 인공지능이라는 분야 등장
- 초창기는 지식기반 방식이 주류
 - 예) “구멍이 2개이고 중간 부분이 홀쭉하며, 맨 위와 아래가 둥근 모양이라면 8이다”



지식기반 방식에서 기계 학습으로의 대전환

- [illegible]



- 사람은 변화가 심한 장면을 아주 쉽게 인식하지만, 왜 그렇게 인식하는지 서술하지는 못함



기계학습이란? | 지식기반 방식에서 기계 학습으로의 대전환

- 인공지능의 주도권 전환
 - 지식기반 → 기계 학습
 - 기계 학습: 데이터 중심 접근방식



기계학습이란? | 기계 학습 개념

- 간단한 기계 학습 예제
 - 가로축은 시간, 세로축은 이동체의 위치
 - 관측한 4개의 점이 데이터




그림 1-4 간단한 기계 학습 예제

- 예측prediction 문제
 - 임의의 시간이 주어지면 이때 이동체의 위치는?
 - 회귀regression 문제와 분류classification 문제로 나뉨
 - 회귀는 목표치가 실수, 분류는 부류값 ([그림 1-4]는 회귀 문제)

기계학습이란? | 기계 학습 개념

- 훈련집합

- 가로축은 **특징**, 세로축은 **목표치**
- 관측한 4개의 점이 **훈련집합**을 구성함

$$\text{훈련집합: } \mathbb{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}, \quad \mathbb{Y} = \{y_1, y_2, \dots, y_n\} \quad (1.1)$$




그림 1-4 간단한 기계 학습 예제

[그림 1-4] 예제의 훈련집합

$$\mathbb{X} = \{\mathbf{x}_1 = (2.0), \mathbf{x}_2 = (4.0), \mathbf{x}_3 = (6.0), \mathbf{x}_4 = (8.0)\}$$

$$\mathbb{Y} = \{y_1 = 3.0, y_2 = 4.0, y_3 = 5.0, y_4 = 6.0\}$$

기계학습이란? | 기계 학습 개념

- 데이터를 어떻게 모델링할 것인가
 - 눈대중으로 보면 직선을 이루므로 직선을 선택하자 → **모델로 직선을 선택**한 셈
 - 직선 모델의 수식
 - 2개의 **매개변수** w 와 b
- $$y = \underline{wx} + \underline{b} \quad (1.2)$$
- 기계 학습은
 - 가장 정확하게 예측할 수 있는, 즉 최적의 매개변수를 찾는 작업
 - 처음에는 최적값을 모르므로 임의의 값에서 시작하고, 점점 성능을 개선하여 최적에 도달
 - [그림 1-4]의 예에서는 f_1 에서 시작하여 $f_1 \rightarrow f_2 \rightarrow f_3$
 - 최적인 f_3 은 $w=0.5$ 와 $b=2.0$



기계학습이란? | 기계 학습 개념

- 학습을 마치면,
 - 예측에 사용
 - 예) 10.0 순간의 이동체 위치를 알고자 하면, $f_3(10.0)=0.5*10.0+2.0=7.0$ 이라 예측함
- 기계 학습의 궁극적인 목표
 - 훈련집합에 없는 새로운 샘플에 대한 오류를 최소화 (새로운 샘플 집합: 테스트 집합)
 - 테스트 집합에 대한 높은 성능을 **일반화**generalization 능력이라 부름



기계학습이란? | 사람의 학습과 기계 학습

기준	사람의 학습	기계 학습
학습 과정	능동적	수동적
데이터 형식	자연에 존재하는 그대로	일정한 형식에 맞추어 사람이 준비함
동시에 학습 가능한 과업 수	자연스럽게 여러 과업을 학습	하나의 과업만 가능
학습 원리에 대한 지식	매우 제한적으로 알려져 있음	모든 과정이 밝혀져 있음
수학 의존도	매우 낮음	매우 높음
성능 평가	경우에 따라 객관적이거나 주관적	객관적(수치로 평가, 예를 들어 정확률 99.8%)
역사	수백만 년	60년 가량



특징 공간에 대한 이해


- 1차원과 2차원 특징 공간
- 다차원 특징 공간



특징 공간에 대한 이해 I

1차원과 2차원 특징 공간

- 1차원 특징 공간 →



(a) 1차원 특징 공간(왼쪽: 특징과 목표값을 축으로 표시, 오른쪽: 특징만 축으로 표시)

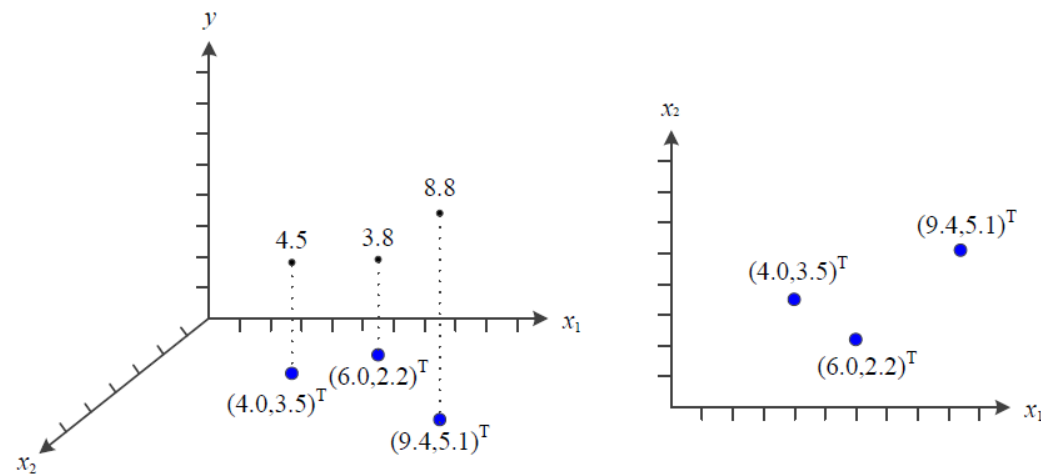
- 2차원 특징 공간 →

- 특징 벡터 표기

- $\mathbf{x} = (x_1, x_2)^T$

- 예시

- $\mathbf{x} = (\text{몸무게}, \text{키})^T$, $y = \text{장타율}$
 - $\mathbf{x} = (\text{체온}, \text{두통})^T$, $y = \text{감기 여부}$

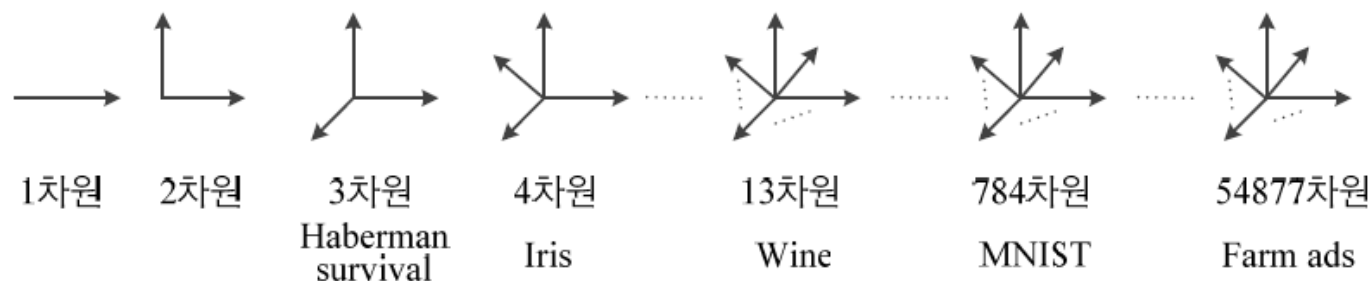


(b) 2차원 특징 공간(왼쪽: 특징 벡터와 목표값을 축으로 표시, 오른쪽: 특징 벡터만 축으로 표시)

그림 1-5 특징 공간과 데이터의 표현

특징 공간에 대한 이해 | 다차원 특징 공간

- 다차원 특징 공간 예제



Haberman survival: $\mathbf{x} = (\text{나이}, \text{수술년도}, \text{양성 림프샘 개수})^T$

Iris: $\mathbf{x} = (\text{꽃받침 길이}, \text{꽃받침 너비}, \text{꽃잎 길이}, \text{꽃잎 너비})^T$

Wine: $\mathbf{x} = (\text{Alcohol}, \text{Malic acid}, \text{Ash}, \text{Alcalinity of ash}, \text{Magnesium}, \text{Total phenols}, \text{Flavanoids}, \text{Nonflavanoid phenols}, \text{Proanthocyanins}, \text{Color intensity}, \text{Hue}, \text{OD280 / OD315 of diluted wines}, \text{Proline})^T$

MNIST: $\mathbf{x} = (\text{화소1}, \text{화소2}, \dots, \text{화소784})^T$

Farm ads: $\mathbf{x} = (\text{단어1}, \text{단어2}, \dots, \text{단어54877})^T$

그림 1-6 다차원 특징 공간

특징 공간에 대한 이해 | 다차원 특징 공간

- d -차원 데이터
 - 특징 벡터 표기: $\mathbf{x}=(x_1, x_2, \dots, x_d)^T$
- d -차원 데이터를 위한 학습 모델
 - 직선 모델을 사용하는 경우 매개변수 수= $d+1$

$$y = \underline{w_1}x_1 + \underline{w_2}x_2 + \dots + \underline{w_d}x_d + \underline{b} \quad (1.3)$$

- 2차 곡선 모델을 사용하면 매개변수 수가 크게 증가
 - 매개변수 수= d^2+d+1
 - 예) Iris 데이터: $d=4$ 이므로 21개의 매개변수
 - 예) MNIST 데이터: $d=784$ 이므로 615,441개의 매개변수

$$y = \underline{w_1}x_1^2 + \underline{w_2}x_2^2 + \dots + \underline{w_d}x_d^2 + \underline{w_{d+1}}x_1x_2 + \dots + \underline{w_{d^2}}x_{d-1}x_d + \underline{w_{d^2+1}}x_1 + \dots + \underline{w_{d^2+d}}x_d + \underline{b}$$

데이터에 대한 이해

- 데이터 생성 과정
- 데이터베이스의 중요성
- 데이터베이스 크기와 기계 학습 성능
- 데이터 가시화



데이터에 대한 이해

- 과학 기술의 발전 과정




그림 1-8 과학기술의 발전 과정

- 기계 학습

- 기계 학습이 푸는 문제는 훨씬 복잡함
 - 예) '8' 숫자 패턴과 '단추' 패턴의 다양한 변화 양상
- 단순한 수학 공식으로 표현 불가능함
- 자동으로 모델을 찾아내는 과정이 필수

데이터에 대한 이해 | 데이터 생성 과정

- 데이터 생성 과정을 완전히 아는 인위적 상황의 예제
 - 예) 두 개 주사위를 던져 나온 눈의 합을 x 라 할 때, $y=(x-7)^2+1$ 점을 받는 게임
 - 이런 상황을 ‘데이터 생성 과정을 완전히 알고 있다’고 말함
 - x 를 알면 정확히 y 를 예측할 수 있음
 - 실제 주사위를 던져 $\mathbb{X} = \{3,10,8,5\}$ 를 얻었다면, $\mathbb{Y} = \{17,10,2,5\}$
 - x 의 발생 확률 $P(x)$ 를 정확히 알 수 있음
 - $P(x)$ 를 알고 있으므로, 새로운 데이터 생성 가능
- 실제 기계 학습 문제
 - 데이터 생성 과정을 알 수 없음
 - 단지 주어진 훈련집합 \mathbb{X}, \mathbb{Y} 로 예측 모델 또는 생성 모델을 근사 추정할 수 있을 뿐



데이터에 대한 이해 | 데이터베이스의 중요성

- 데이터베이스의 품질

- 주어진 응용에 맞는 충분히 다양한 데이터를 충분한 양만큼 수집 → 추정 정확도 높아짐
 - 예) 정면 얼굴만 가진 데이터베이스로 학습하고 나면, 기운 얼굴은 매우 낮은 성능
- 주어진 응용 환경을 자세히 살핀 다음 그에 맞는 데이터베이스 확보는 아주 중요함

- 아주 많은 공개 데이터베이스

- 기계 학습의 초파리로 여겨지는 3가지 데이터베이스: Iris, MNIST, ImageNet
- 위키피디아에서 'list of datasets for machine learning research'로 검색
- UCI Repository (현재 기준으로 622개 데이터베이스 제공)



데이터에 대한 이해 | 데이터베이스의 중요성

- Iris 데이터베이스는 통계학자인 피셔 교수가 1936년에 캐나다 동부 해안의 가스페 반도에 서식하는 3종의 붓꽃(*setosa*, *versicolor*, *virginica*)을 50송이씩 채취하여 만들었다[Fisher1936]. 150개 샘플 각각에 대해 꽃받침 길이, 꽃받침 너비, 꽃잎 길이, 꽃잎 너비를 측정하여 기록하였다. 따라서 4차원 특징 공간이 형성되며 목표값은 3종을 숫자로 표시함으로써 1, 2, 3 값 중의 하나이다. <http://archive.ics.uci.edu/ml/datasets/Iris>에 접속하여 내려받을 수 있다.

Sepal length ◆	Sepal width ◆	Petal length ◆	Petal width ◆	Species ◆
5.2	3.5	1.4	0.2	<i>I. setosa</i>
4.9	3.0	1.4	0.2	<i>I. setosa</i>
4.7	3.2	1.3	0.2	<i>I. setosa</i>
4.6	3.1	1.5	0.2	<i>I. setosa</i>
7.0	3.2	4.7	1.4	<i>I. versicolor</i>
6.4	3.2	4.5	1.5	<i>I. versicolor</i>
6.9	3.1	4.9	1.5	<i>I. versicolor</i>
5.5	2.3	4.0	1.3	<i>I. versicolor</i>
6.3	3.3	6.0	2.5	<i>I. virginica</i>
5.8	2.7	5.1	1.9	<i>I. virginica</i>
7.1	3.0	5.9	2.1	<i>I. virginica</i>
6.3	2.9	5.6	1.8	<i>I. virginica</i>

Setosa



Versicolor



Virginica




데이터에 대한 이해 | 데이터베이스의 중요성

- MNIST 데이터베이스는 미국표준국(NIST)에서 수집한 필기 숫자 데이터베이스로, 훈련집합 60,000자, 테스트집합 10,000자를 제공한다. <http://yann.lecun.com/exdb/mnist>에 접속하면 무료로 내려받을 수 있으며, 1988년부터 시작한 인식률 경쟁 기록도 볼 수 있다. 2017년 8월 기준으로는 [Ciresan2012] 논문이 0.23%의 오류율로 최고 자리를 차지하고 있다. 테스트집합에 있는 10,000개 샘플에서 단지 23개만 틀린 것이다.



데이터에 대한 이해 | 데이터베이스의 중요성

- ImageNet 데이터베이스는 정보검색 분야에서 만든 WordNet의 단어 계층 분류를 그대로 따랐고, 부류마다 수백에서 수천 개의 영상을 수집하였다[Deng2009]. 총 21,841개 부류에 대해 총 14,197,122개의 영상을 보유하고 있다. 그중에서 1,000개 부류를 뽑아 ILSVRC(ImageNet Large Scale Visual Recognition Challenge)라는 영상인식 경진대회를 2010년부터 매년 개최하고 있다.



(a) 'swing' 부류




(b) 'Great white shark' 부류

데이터에 대한 이해 |




데이터베이스 크기와 기계 학습 성능

- 데이터베이스의 왜소한 크기
 - 예) MNIST: 28*28 흑백 비트맵이라면 서로 다른 총 샘플 수는 2^{784} 가지이지만, MNIST는 고작 6만 개 샘플



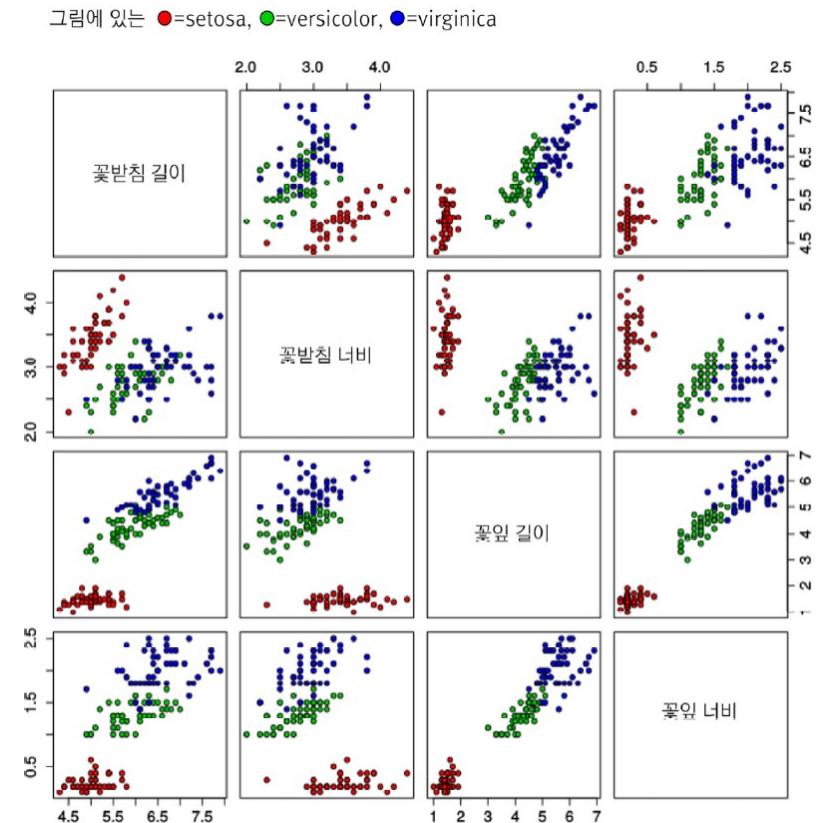
데이터에 대한 이해 I

데이터베이스 크기와 기계 학습 성능

- 왜소한 데이터베이스로 어떻게 높은 성능을 달성하는가?
 - 방대한 공간에서 실제 데이터가 발생하는 곳은 매우 작은 부분 공간임
 -  ,  와 같은 샘플의 발생 확률은 거의 0
 - 매니폴드 가정
 -  와 같이 일정한 규칙에 따라 매끄럽게 변화

데이터에 대한 이해 | 데이터 가시화

- 4차원 이상의 초공간은 한꺼번에 가시화 불가능
- 여러 가지 가시화 기법
 - 2개씩 조합하여 여러 개의 그래프 그림



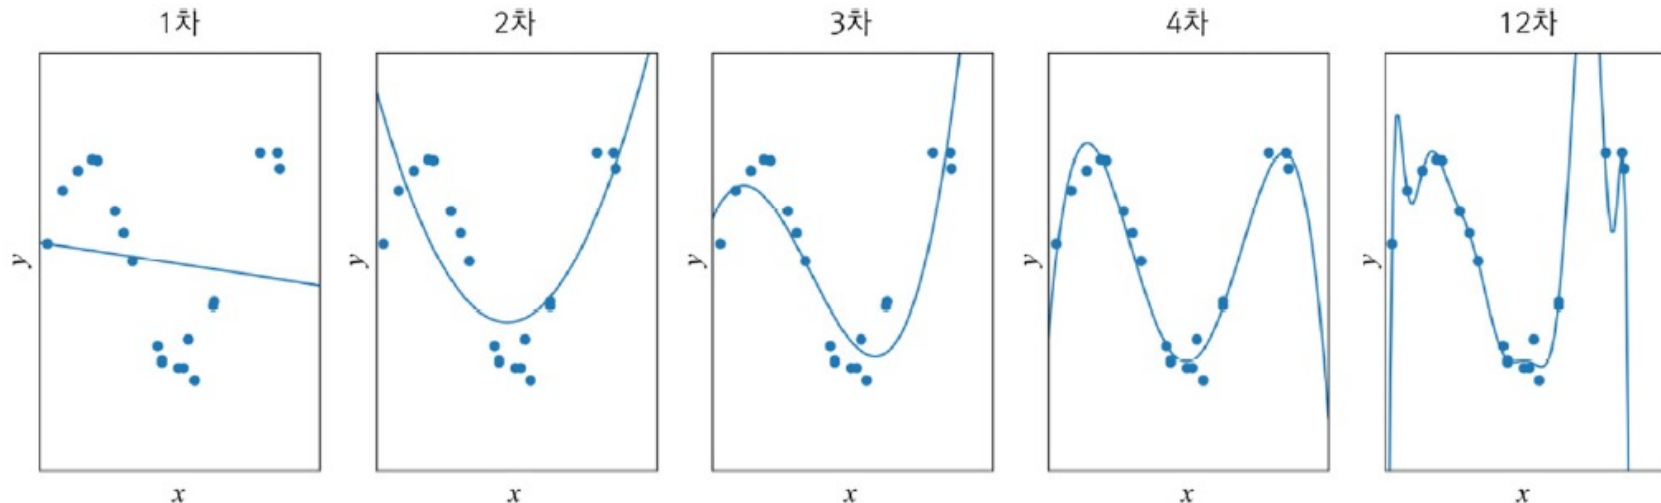
모델 선택

- 과소적합과 과잉적합
- 바이어스와 분산
- 모델 선택의 한계와 현실적인 해결책



모델 선택 | 과소적합과 과잉적합

- 아래 그림의 1차 모델은 **과소적합**
 - 모델의 '용량이 작아' 오차가 클 수밖에 없는 현상
- 비선형 모델을 사용하는 대안
 - 2차, 3차, 4차, 12차는 다항식 곡선을 선택한 예
 - 1차(선형)에 비해 오차가 크게 감소함



모델 선택 | 과소적합과 과잉적합

• 과잉적합

- 12차 다항식 곡선을 채택한다면 훈련집합에 대해 거의 완벽하게 근사화함
- 하지만 '새로운' 데이터를 예측한다면 큰 문제 발생
 - x_0 에서 빨간 막대 근방을 예측해야 하지만 빨간 점을 예측
- 이유는 '용량이 크기' 때문. 학습 과정에서 잡음까지 수용 → 과잉적합 현상
- 적절한 용량의 모델을 선택하는 모델 선택 작업이 필요함




그림 1-14 과잉적합되었을 때 부정확한 예측 현상


모델 선택 | 바이어스와 분산

- 1차~12차 다항식 모델의 비교 관찰
 - 1~2차는 훈련집합과 테스트집합 모두 낮은 성능
 - 12차는 훈련집합에 높은 성능을 보이나 테스트집합에서는 낮은 성능 → 낮은 일반화 능력
 - 3~4차는 훈련집합에 대해 12차보다 낮겠지만 테스트집합에는 높은 성능 → 높은 일반화 능력




모델 선택 | 바이어스와 분산

- 훈련집합을 여러 번 수집하여 1차~12차에 적용하는 실험
 - 2차는 매번 큰 오차 → 바이어스가 큼. 하지만 비슷한 모델을 얻음 → 낮은 분산
 - 12차는 매번 작은 오차 → 바이어스가 작음. 하지만 크게 다른 모델을 얻음 → 높은 분산
 - 일반적으로 용량이 작은 모델은 바이어스는 크고 분산은 작음. 복잡한 모델은 바이어스는 작고 분산은 큼
 - 바이어스와 분산은 트레이드오프 관계




(a) 2차 모델(바이어스는 크고, 분산은 작음)



(b) 12차 모델(바이어스는 작고, 분산은 큼)

모델 선택 | 바이어스와 분산

- 기계 학습의 목표
 - 낮은 바이어스와 낮은 분산을 가진 예측기 제작이 목표. 즉 왼쪽 아래 상황



- 하지만 바이어스와 분산은 트레이드오프 관계
- 따라서 바이어스 희생을 최소로 유지하며 분산을 최대한 낮추는 전략 필요

모델 선택 |

모델 선택의 한계와 현실적인 해결책

- 알고리즘 에서 모델 집합 요
 - 서로 다른 차수의 다항식이 요 (1차, 2차, 3차, ..., 12차)
 - 현실에서는 아주 다양
 - Support Vector Machine (SVM), 트리분류기, 신경망, 강화 학습 등이 선택 대상
- 현실에서는 경험으로 큰 틀 먼저 선택
 - 모델 선택 알고리즘으로 세부 모델 선택하는 전략 사용



모델 선택 |

모델 선택의 한계와 현실적인 해결책

- 이런 경험적인 접근방법에 대한 『Deep Learning』 책의 비유

“To some extent, we are always trying to fit a square peg(the data generating process) into a round hole(our model family). 어느 정도 우리가 하는 일은 항상 둥근 홈(우리가 선택한 모델)에 네모 막대기(데이터 생성 과정)를 끼워 넣는 것이라고 말할 수 있다[Goodfellow2016(222쪽)].”

- 현대 기계 학습의 전략

- 용량이 충분히 큰 모델을 선택 한 후, 선택한 모델이 정상을 벗어나지 않도록 여러 가지 **규제**regularization 기법을 적용함
- 예) 12차 다항식을 선택한 후 적절히 규제를 적용



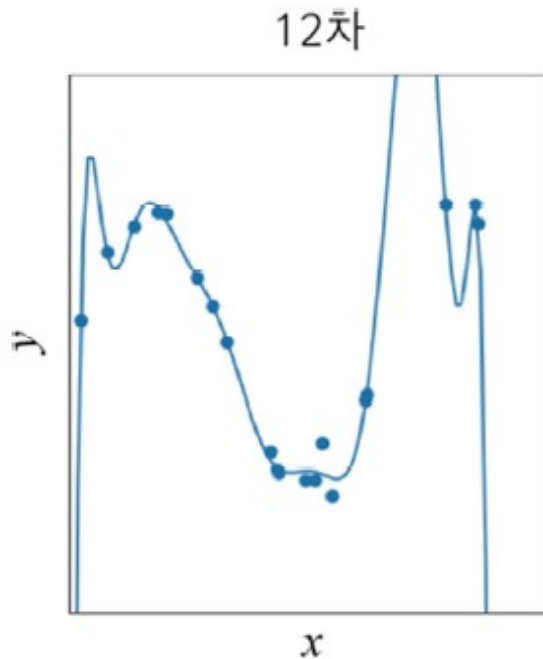
규제

- 데이터 확대
- 가중치 감소




규제 | 데이터 확대


- 데이터를 더 많이 수집하면 일반화 능력이 향상됨



(a) 훈련집합의 크기 = 20




(b) 훈련집합의 크기 = 40



(c) 훈련집합의 크기 = 60

규제 | 데이터 확대

- 데이터 수집은 많은 비용이 듦
 - 그라운드 트루스를 사람이 일일이 레이블링해야 함
- 인위적으로 데이터 확대
 - 훈련집합에 있는 샘플을 변형함
 - 약간 회전 또는 와핑 (부류 소속이 변하지 않게 주의)



규제 | 가중치 감쇠


- 가중치를 작게 조절하는 기법

- 아래 12차 곡선은 가중치가 매우 큼


$$y = 1005.7x^{12} - 27774.4x^{11} + \dots - 22852612.5x^1 - 12.8$$

- 가중치 감쇠는 개선된 목적함수를 이용하여 가중치를 작게 조절하는 규제 기법
 - 식 (1.11)의 두 번째 항은 규제 항으로서 가중치 크기를 작게 유지해줌

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n (f_{\theta}(\mathbf{x}_i) - y_i)^2 + \lambda \|\theta\|_2^2 \quad (1.11)$$



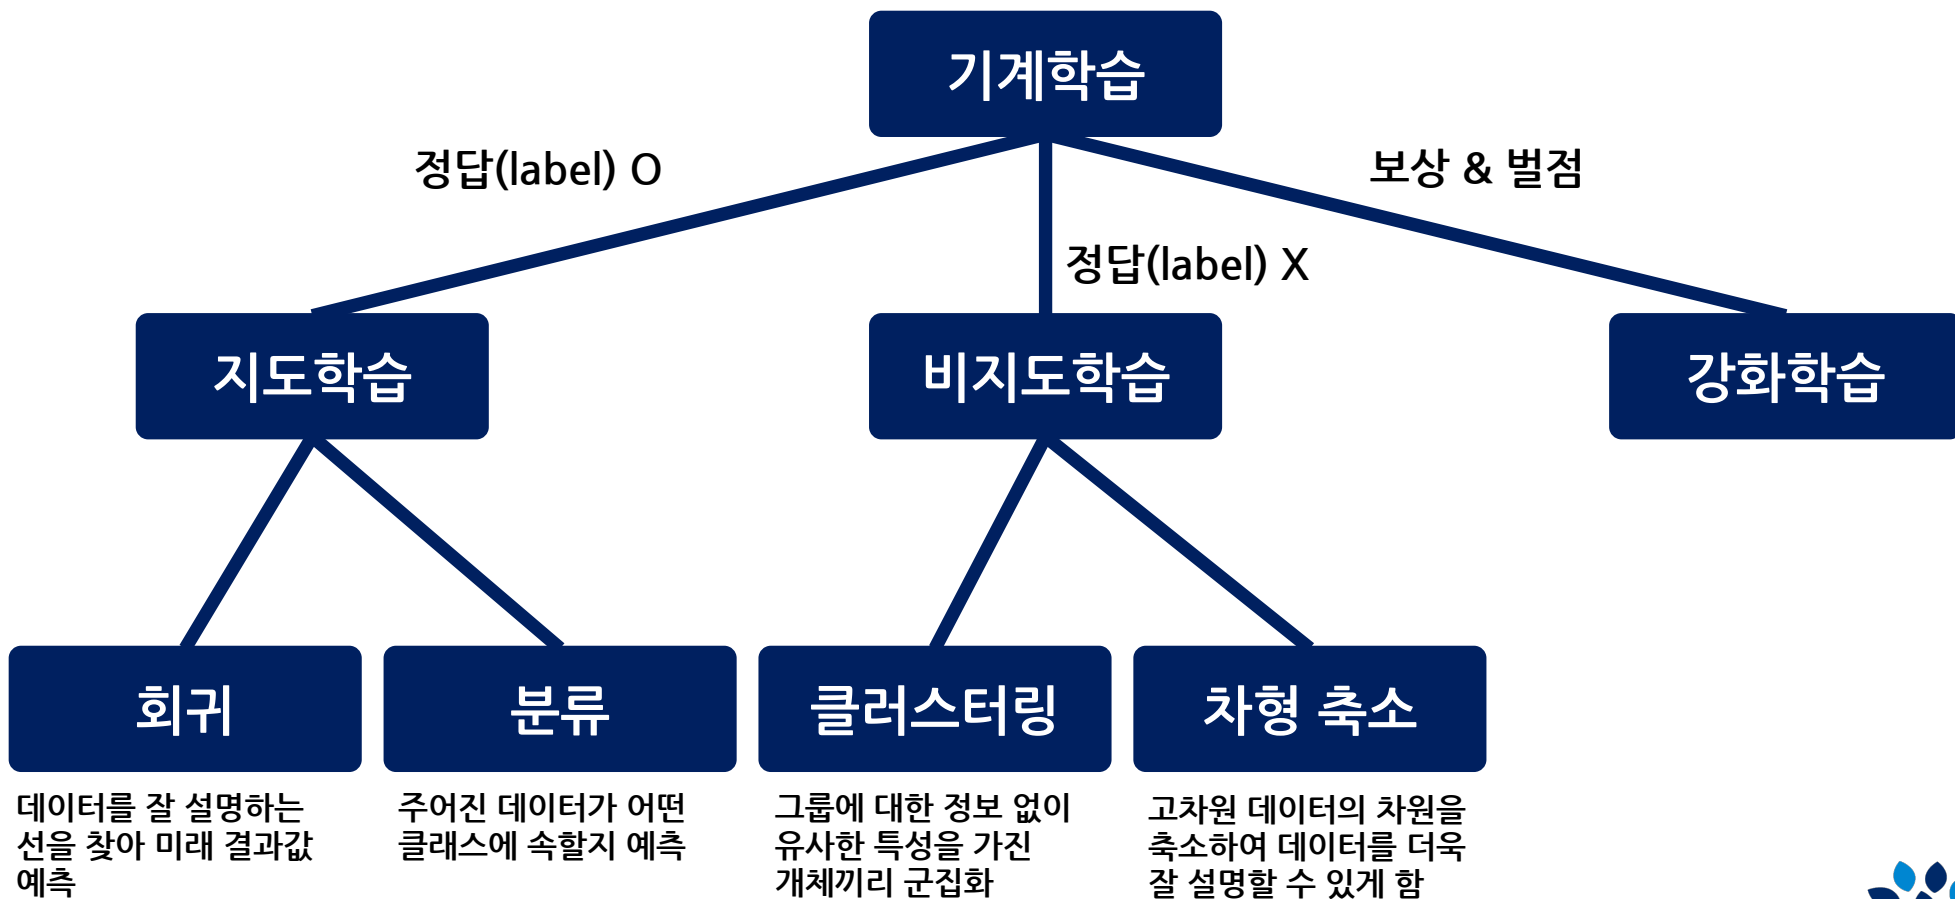
(a) 가중치 감쇠 적용 안 함[식 (1.8)의 목적함수]



(b) 가중치 감쇠 적용함[식 (1.11)의 목적함수]

$y = 10.779x^{12} - 42.732x^{11} + \dots - 2.379x^1 + 0.119$

기계 학습 유형 | 지도 방식에 따른 유형



기계 학습 유형 | 지도 방식에 따른 유형

- 지도 학습 (Supervised Learning)

- 정답이 주어진 상태에서 학습하는 알고리즘
- 훈련 데이터(Training Data)로부터 하나의 함수를 유추
- 지도학습 종류
 - 회귀분석(Regression)/예측: 연속적인 값을 출력하는 것
 - 분류(Classification): 주어진 입력 벡터가 어떤 종류의 값인지 표식하는 것



기계 학습 유형 | 지도 방식에 따른 유형

- 비지도 학습 (Unsupervised Learning)

- 정답이 주어지지 않은 상태에서 데이터의 특성을 학습하는 알고리즘
- 데이터가 어떻게 구성되었는지를 알아내는 문제를 해결
- 지도 학습 혹은 강화 학습과는 달리 입력값에 대한 목표치(분류된 값)가 없음
- 비지도학습 종류: 군집화, 연관 규칙
 - 데이터의 주요 특징을 요약하고 설명



기계 학습 유형 | 지도 방식에 따른 유형

- 강화 학습 (Reinforcement Learning)

- 보상 혹은 벌칙과 함께 여러 번의 시행착오를 거쳐 스스로 학습하는 방법.
 - 분류할 수 있는 데이터 혹은 정답이 존재하지 않음
 - 행동에 보상 혹은 벌칙을 받으며 학습
- 보상을 최대한 많이 얻도록 하는 행동을 유도하도록 학습을 진행
- 예제: 아이가 일어서고 걷는 방법, 구글의 알파고



Thank you

