

기계학습 개론

- Qualitative Classification (질적 분류)

정보통신공학과

Prof. Jinkyu Kang



MYONGJI
UNIVERSITY

이번주 수업의 목차

- 결정트리
 - 원리
 - 노드에서의 질문
 - 학습 알고리즘
 - 특성



들어가는 말

- 세상에는 참으로 많은 데이터가 있다.
 - 계량 데이터
 - 점수, 매출액, GDP, 속도, 마찰계수, 토끼 개체수 등
 - 거리 개념 있다. 5는 31보다 크다. 5는 10보다 7에 가깝다.
 - 비계량 데이터
 - 직업, 행정 구역, 혈액형, 성씨, PC 브랜드 등
 - 거리 개념 없다. ‘O형은 B형보다 A형에 가깝다’는 성립 안한다.



들어가는 말

- 비계량 데이터의 분류를 다룸
 - 질적 분류기
 - 결정 트리
 - 스트링 인식기

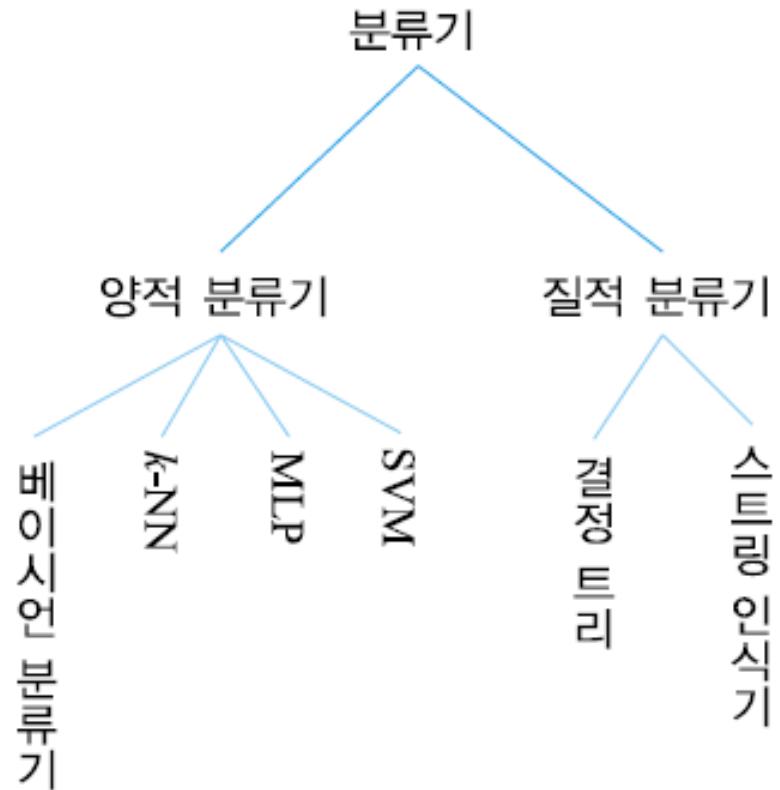


그림 6.1 양적 분류기와 질적 분류기

결정트리 | 원리

- 결정 트리의 원리
 - 스무고개와 개념이 비슷
 - 최적 기준에 따라 자동으로 질문을 만들어야 함
- 몇 가지 고려 사항
 1. 노드에서 몇 개의 가지로 나눌 것인가?
 2. 각 노드의 질문을 어떻게 만들 것인가?
 3. 언제 멈출 것인가?
 4. 앞 노드를 어느 부류에 할당할 것인가?

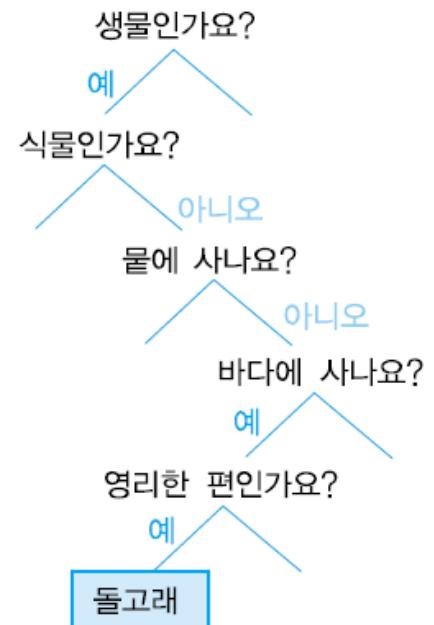
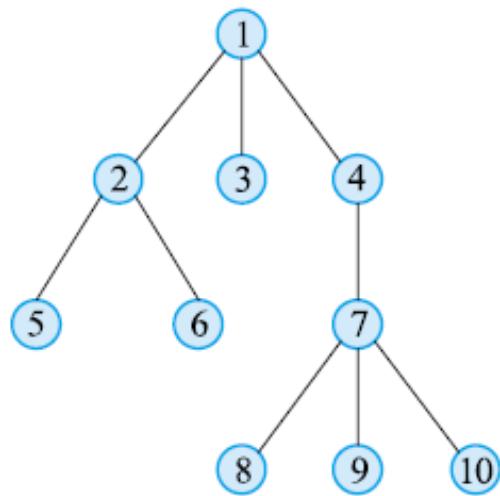


그림 6.2 스무고개 놀이

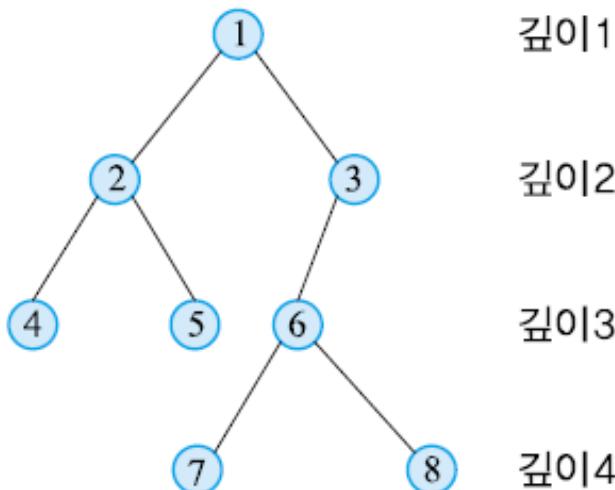


결정트리 | 원리

- 결정 트리의 표현
 - 트리 또는 이진 트리 사용



(a) 트리



(b) 이진 트리

그림 6.3 트리와 이진 트리

결정트리 | 노드에서의 질문

- 결정 트리의 노드
 - 노드의 분기

$$\left. \begin{array}{l} X_{Tleft} \cup X_{Tright} = X_T \\ X_{Tleft} \cap X_{Tright} = \emptyset \end{array} \right\} \quad (6.1)$$

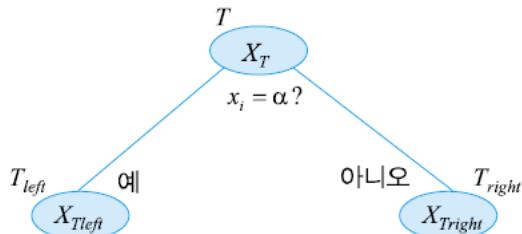


그림 6.5 노드의 분기

- 질문 $x_i = \alpha?$ 어떻게 만들 것인가?
 - d 개의 특징이 있고 그들이 평균 n 개의 값을 가진다면 dn 개의 후보 질문
 - 그들 중 어느 것을 취해야 가장 유리한가?

결정트리 | 노드에서의 질문

- 유리한 정도의 판단 기준은?
 - X_{Tleft} 와 X_{Tright} 가 동질일 수록 좋다.

- 불순도 측정 기준

- 엔트로피 $im(T) = - \sum_{i=1}^M P(\omega_i | T) \log_2 P(\omega_i | T)$ (6.2)

- 지니 불순도 $im(T) = 1 - \sum_{i=1}^M P(\omega_i | T)^2 = \sum_{i \neq j} P(\omega_i | T)P(\omega_j | T)$ (6.3)

- 오분류 불순도 $im(T) = 1 - \max_i P(\omega_i | T)$ (6.4)

- 노드 T 에서 ω_i 가 발생할 확률은

$$P(\omega_i | T) = \frac{X_T \text{에서 } \omega_i \text{에 속한 샘플의 수}}{|X_T|} \quad (6.5)$$

결정트리 | 노드에서의 질문

- 예제 1) 불순도 측정

노드 T 의 샘플 집합 X_T 가 아래와 같다고 하자.

$$X_T = \{(\mathbf{x}_1, \omega_2), (\mathbf{x}_2, \omega_1), (\mathbf{x}_3, \omega_3), (\mathbf{x}_4, \omega_2), (\mathbf{x}_5, \omega_2), (\mathbf{x}_6, \omega_2), (\mathbf{x}_7, \omega_1), (\mathbf{x}_8, \omega_3), (\mathbf{x}_9, \omega_1)\}$$

$$P(\omega_1 | T) = 3/9, \quad P(\omega_2 | T) = 4/9, \quad P(\omega_3 | T) = 2/9$$

샘플	특징 벡터			부류
	x_1 (직업)	x_2 (선호 품목)	x_3 (몸무게)	
1	3	1	50.6	ω_2
2	2	3	72.8	ω_1
3	3	5	88.7	ω_3
4	2	2	102.2	ω_2
5	5	5	92.3	ω_2
6	3	4	65.3	ω_2
7	2	3	67.8	ω_1
8	7	1	47.8	ω_3
9	2	3	45.6	ω_1

엔트로피 불순도: $im(T) = -\left(\frac{3}{9} \log_2 \frac{3}{9} + \frac{4}{9} \log_2 \frac{4}{9} + \frac{2}{9} \log_2 \frac{2}{9}\right) = 1.5305$

지니 불순도: $im(T) = 1 - \left(\frac{3^2}{9^2} + \frac{4^2}{9^2} + \frac{2^2}{9^2}\right) = 0.642$

오분류 불순도: $im(T) = 1 - \frac{4}{9} = 0.556$

결정트리 | 노드에서의 질문

- 노드에서 질문 선택
 - 불순도 감소량이 최대인 질문을 취함
 - 불순도 감소량

$$\Delta im(T) = im(T) - \frac{|X_{T_{left}}|}{|X_T|} im(T_{left}) - \frac{|X_{T_{right}}|}{|X_T|} im(T_{right}) \quad (6.6)$$

결정트리 | 노드에서의 질문

- 노드에서 질문 생성
 - 비계량인 경우 $x_i = \alpha?$
 - 계량인 경우 $x_i < \alpha?$
 - 이산
 - 이산 값에 따라 α 를 결정
 - 연속
 - 실수 범위를 구간화 하여 α 결정
 - 또는 샘플의 값 분포를 보고 두 값의 가운데를 α 로 결정

결정트리 | 노드에서의 질문

- 예제 2) 후보 질문 생성

직업 (x_1): [1,7]의 정수 (1 = 디자이너, 2 = 스포츠맨, 3 = 교수, 4 = 의사, 5 = 공무원, 6 = NGO, 7 = 무직)

선호 품목 (x_2): [1,5]의 정수 (1 = 의류, 2 = 전자 제품, 3 = 스포츠 용품, 4 = 책, 5 = 음식)

몸무게 (x_3): 실수

x_1 에 의한 후보 질문: $x_1=1?$, $x_1=2?$, $x_1=3?$, $x_1=4?$, $x_1=5?$, $x_1=6?$, $x_1=7?$

x_2 에 의한 후보 질문: $x_2=1?$, $x_2=2?$, $x_2=3?$, $x_2=4?$, $x_2=5?$

표에서 x_3 의 값의 분포를 조사하면,

45.6, 47.8, 50.6, 65.3, 67.8, 72.8, 88.7, 92.3, 102.2

x_3 에 의한 후보 질문: $x_3 < 46.7?$, $x_3 < 49.2?$, $x_3 < 57.95?$, $x_3 < 66.55?$, $x_3 < 70.3?$,
 $x_3 < 80.75?$, $x_3 < 90.5?$, $x_3 < 97.25?$

결정트리 | 노드에서의 질문

- 예제 3) 불순도 감소량

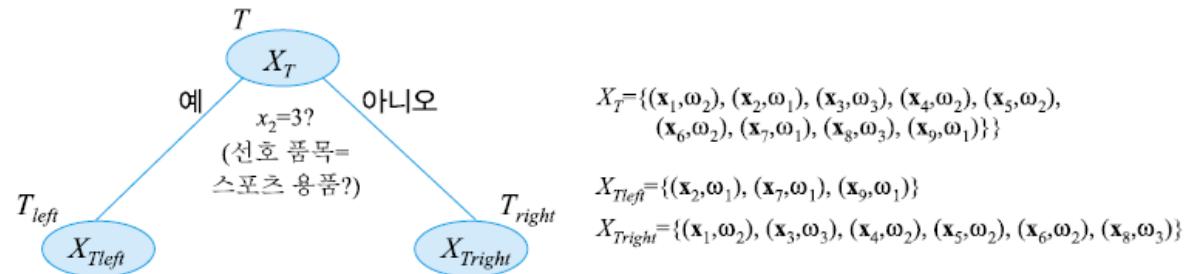


그림 6.6 '선호 품목=스포츠 용품?' 이라는 질문에 따른 분기 결과

$$(6.6) \text{의 불순도 감소량 } \Delta im(T) = 0.642 - \frac{3}{9} * 0.0 - \frac{6}{9} * 0.444 = 0.346$$

결정트리 I

Python을 이용한 불순도 감소량 계산

- $x1==1?$: 0.0
 - $x1==2?$: 0.20864197530864198
 - $x1==3?$: 0.0864197530864198
 - $x1==4?$: 0.0
 - $x1==5?$: 0.058641975308642014
 - $x1==6?$: 0.0
 - $x1==7?$: 0.11419753086419748
 - $x3<46.7?$: 0.086419753
 - $x3<49.2?$: 0.086419753
 - $x3<57.95?$: 0.012345679
 - $x3<66.55?$: 0.008641975
 - $x3<70.3?$: 0.008641975
 - $x3<80.75?$: 0.08641975
 - $x3<90.5?$: 0.13403880
 - $x3<97.25?$: 0.05864197
-
- $x2==1?$: 0.05467372134038789
 - $x2==2?$: 0.058641975308642014
 - $x2==3?$: 0.345679012345679
 - $x2==4?$: 0.058641975308642014
 - $x2==5?$: 0.05467372134038789



결정트리 | 학습 알고리즘

- 결정 트리 학습 알고리즘
 - 언제 멈출 것인가?
 - 과적합 vs. 설익은 수렴
 - 잎 노드의 부류 할당

T 의 부류를 ω_k 로 한다.
○] 때 $k = \underset{i}{\operatorname{argmax}} P(\omega_i | T)$

알고리즘 [6.1] 결정 트리 학습

입력: 훈련 집합 $X = \{(x_1, t_1), \dots, (x_N, t_N)\}$

출력: 결정 트리 R

알고리즘:

1. 노드 하나를 생성하고 그것을 R 이라 한다. // 이것이 루트 노드이다.
2. $T = R;$
3. $X_T = X;$
4. $\operatorname{split_node}(T, X_T);$ // 루트 노드를 시작점으로 하여 순환 함수를 호출한다.
5. $\operatorname{split_node}(T, X_T) \{$ // 순환 함수
6. 노드 T 에서 후보 질문을 생성한다.
7. 모든 후보 질문의 불순도 감소량을 측정한다. // (6.6) 또는 (6.7) 이용
8. 불순도 감소량이 최대인 질문 q 를 선택한다.
9. **if** (T 가 멈춤 조건을 만족) {
10. T 에 부류를 할당한다.
11. **return;**
12. }
13. **else** {
14. q 로 X_T 를 $X_{T_{left}}$ 와 $X_{T_{right}}$ 로 나눈다.
15. 새로운 노드 T_{left} 와 T_{right} 를 생성한다.
16. $\operatorname{split_node}(T_{left}, X_{T_{left}});$
17. $\operatorname{split_node}(T_{right}, X_{T_{right}});$
18. }
19. }



결정트리 | 특성

- 결정 트리의 특성
 - 특징 값에 대한 제약이 적다.
 - 계량, 비계량, 혼합 특징을 모두 다룰 수 있다.
 - 특징 전처리 불필요
 - 분류 결과가 ‘해석 가능’하다.
 - 인식 작업이 매우 빠르다.
 - 가지치기
 - 사전 가지치기
 - 사후 가지치기
 - 불안정성
 - 결정 트리 학습은 욕심 알고리즘
 - 손실 특징을 다루기 쉽다.
 - 대리 분기

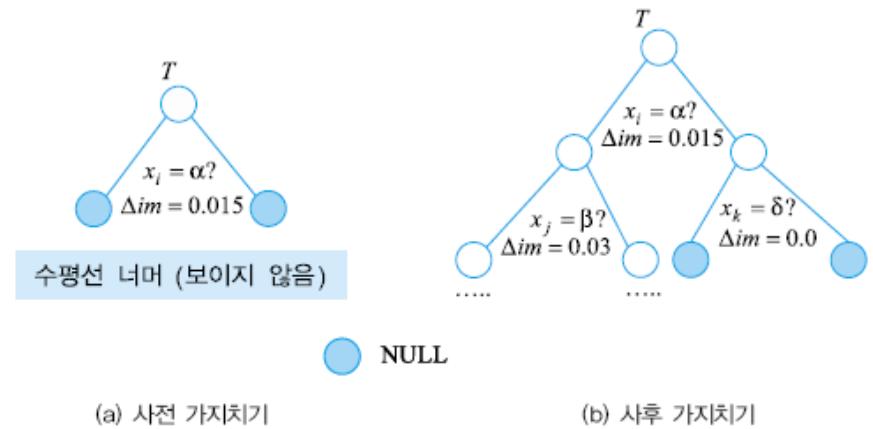


그림 6.7 사전 가지치기와 사후 가지치기

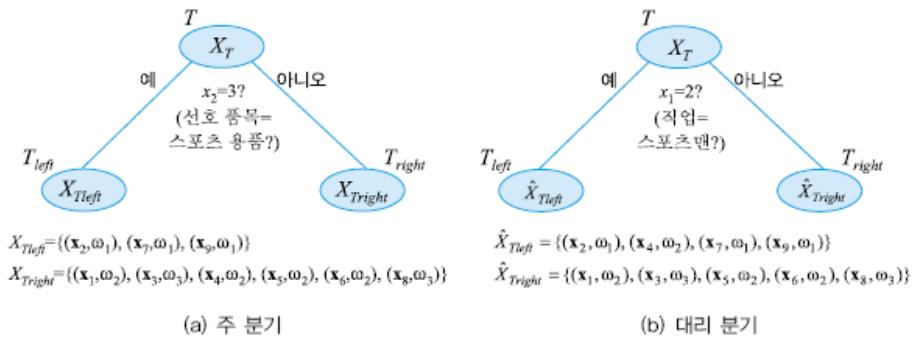


그림 6.8 주 분기와 대리 분기