

기계학습

- Feature extraction (특징 추출)

정보통신공학과

Prof. Jinkyu Kang



MYONGJI
UNIVERSITY

이번주 수업의 목차

- 특징 생성
- 주성분 분석
- Fisher의 선형 분별
- 실용적 관점



들어가는 말

- 특징 추출의 예
 - 필기 숫자 인식

6

- 크기 정규화
- 이진화

00001100
00010000
00100000
01100000
11000110
11000011
11000001
1111110

특
징
추
출

방법 1: 화소 각각을 특징으로 삼음
64 차원 특징 벡터
 $\mathbf{x} = (0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 1, \dots, 1, 1, 0)^T$

방법 2: 가로
이등분과 세로
이 등 분 하 여
검은 화소의
개수 비율을
특징으로 삼음

$$\begin{array}{r} x_2 = 14/10 \\ \hline 14 & 10 \\ \hline 00001100 \\ 00010000 \\ 00100000 \\ 01100000 \\ 11000110 \\ 11000011 \\ 11000001 \\ 1111110 \end{array} \quad \left| \begin{array}{l} 6 \\ 18 \end{array} \right. \quad x_1 = 6/18$$

$$\mathbf{x} = (6/18, 14/10)^T$$

- 특징의 우수성 기준
 - 분별력
 - 차원

또 다른 방법으로는?

특징 생성 | 실제 세계의 다양성

- 특징 생성
 - 외부의 물리적 패턴을 특징 벡터라는 수학적 표현으로 변환

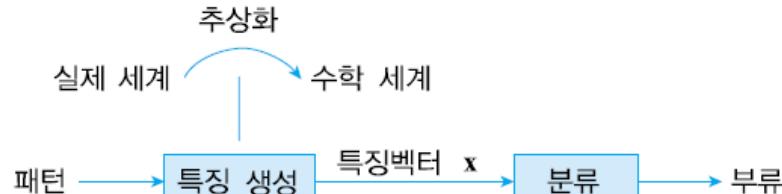


그림 8.1 패턴 인식의 일반적인 흐름

- 특징 생성 과정은 매우 다양
 - 특징 추출은 외부 환경에 맞게 설계해야 하기 때문
 - 숫자와 한글은 다른 특징 필요할 수 있음
 - 한글도 통째로 인식하는 방법과 자소로 분할한 후 인식하는 방법이 다른 특징 필요할 수 있음
 - 정면 얼굴로 국한하는 경우와 제약이 없는 얼굴 인식의 특징은 다를 수 있음

특징 생성 | 특징 추출과 특징 선택

- 센싱으로 얻은 신호의 다양성
 - 영상
 - 시간성 신호
 - 측정 벡터
- 특징 추출과 특징 선택

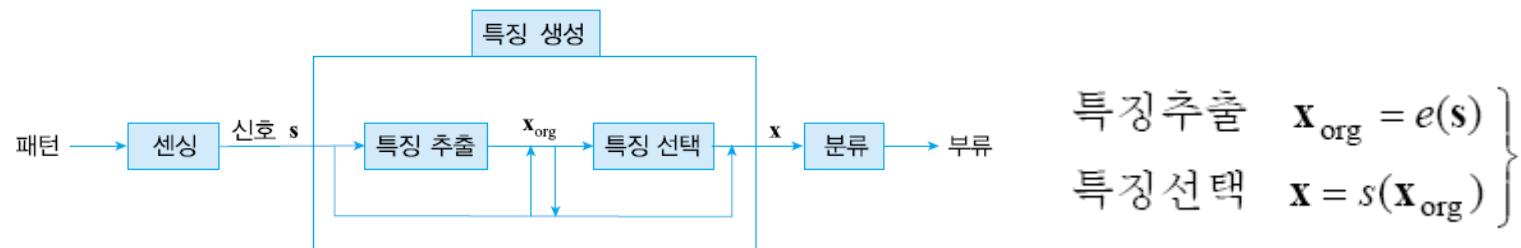


그림 8.2 특징 생성의 절차

- 다양한 상황

$$\left. \begin{array}{l} X = s \\ X = e(s) \\ X = s(e(s)) \end{array} \right\}$$



주성분 분석

- 주성분 분석 principal component analysis (PCA)
 - 훈련 집합을 이용하여 매개 변수를 추정하고 그것을 이용하여 특징 추출함
 - 정보 손실을 최소화하는 조건에서 차원 축소
 - Karhunen-Loeve (KL) 변환 또는 Hotelling 변환이라고도 부름



주성분 분석 | 동기

- 주성분 분석의 동기

- \mathbf{U} 는 ‘정보 손실을 최소화하며’ 신호 \mathbf{s} 를 보다 낮은 차원의 특징 벡터 \mathbf{x} 로 변환 (신호 \mathbf{s} 는 D 차원 > 특징 벡터 \mathbf{x} 는 d 차원)
- 변환 행렬 \mathbf{U} 는 $d \times D$ 행렬
- 두가지 문제
 - 차원 축소를 어떻게 표현할 것인가?
 - 정보 손실을 어떻게 수량화할 것인가?

$$\mathbf{x} = e(\mathbf{s}; \mathbf{U}) = \mathbf{Us} \quad (8.26)$$

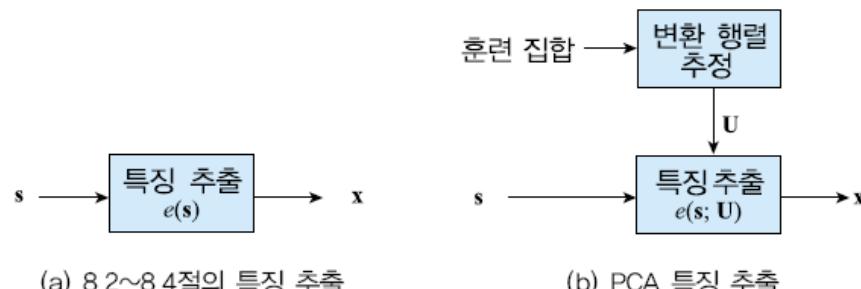


그림 8.12 특징 추출 방법의 비교

주성분 분석 | 동기

- 차원 축소의 표현
 - D 차원 단위 벡터 \mathbf{u} 축으로의 투영

$$\hat{x} = \mathbf{u}^T \mathbf{s}$$

(8.27)

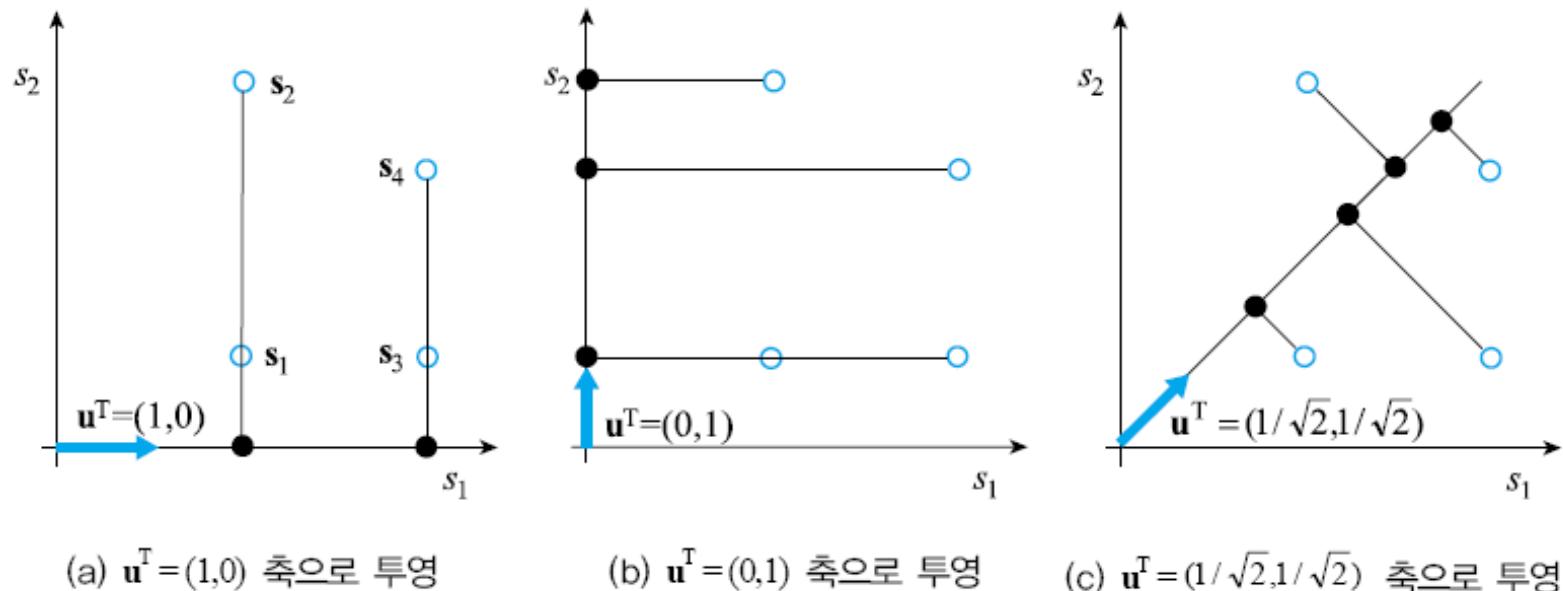


그림 8.13 투영에 의해 2 차원 공간을 1 차원 공간으로 축소

주성분 분석 | 동기

- 정보 손실의 공식화
 - 원래 훈련 집합이 가진 정보란 무엇일까?
 - 샘플들 간의 거리, 그들 간의 상대적인 위치 등
 - 그림 8.13의 세 가지 축 중에 어느 것이 정보 손실이 가장 적은가?
 - PCA는 샘플들이 원래 공간에 ‘퍼져있는 정도를’ 변환된 공간에서 얼마나 잘 **유지**하느냐를 척도로 삼음
 - 이 척도는 변환된 공간에서 샘플들의 분산으로 측정함
- 이러한 아이디어에 따라 문제를 공식화 하면,
 - 변환된 샘플들의 분산을 최대화하는 축 (즉 단위 벡터 \mathbf{u})을 찾아라. (8.28)



주성분 분석 | 동기

- 예제) 변환 공간에서의 분산

원래 샘플

$$\mathbf{s}_1 = (2,1)^T, \mathbf{s}_2 = (2,4)^T, \mathbf{s}_3 = (4,1)^T, \mathbf{s}_4 = (4,3)^T$$

$\mathbf{u}^T = (1,0)$ 축으로 투영 변환된 샘플 분산 1.0

$$\hat{x}_1 = (1 \ 0) \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 2, \quad \hat{x}_2 = (1 \ 0) \begin{pmatrix} 2 \\ 4 \end{pmatrix} = 2, \quad \hat{x}_3 = (1 \ 0) \begin{pmatrix} 4 \\ 1 \end{pmatrix} = 4, \quad \hat{x}_4 = (1 \ 0) \begin{pmatrix} 4 \\ 3 \end{pmatrix} = 4$$

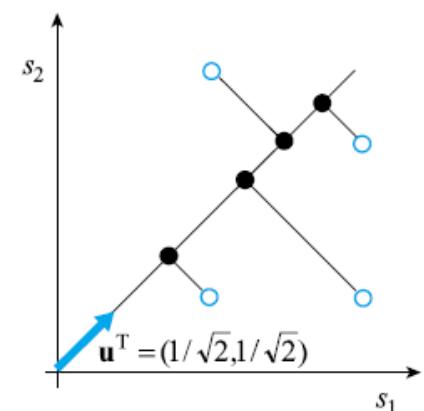
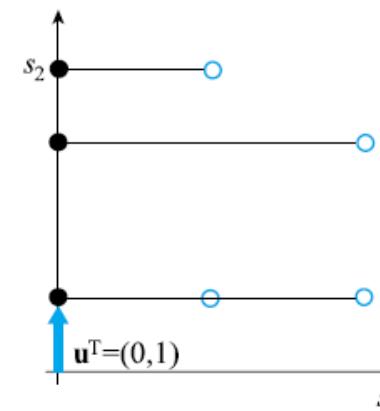
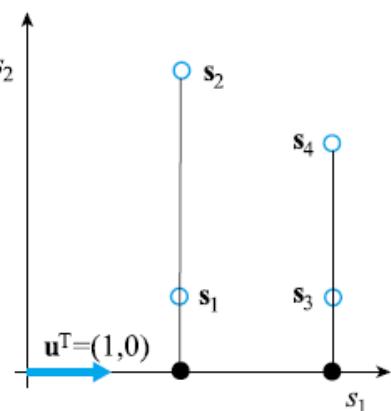
$\mathbf{u}^T = (1/\sqrt{2}, 1/\sqrt{2})$ 축으로 투영 변환된 샘플: 분산 1.0938

$$\hat{x}_1 = (1/\sqrt{2} \ 1/\sqrt{2}) \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \frac{3}{\sqrt{2}}$$

$$\hat{x}_2 = (1/\sqrt{2} \ 1/\sqrt{2}) \begin{pmatrix} 2 \\ 4 \end{pmatrix} = \frac{6}{\sqrt{2}}$$

$$\hat{x}_3 = (1/\sqrt{2} \ 1/\sqrt{2}) \begin{pmatrix} 4 \\ 1 \end{pmatrix} = \frac{5}{\sqrt{2}}$$

$$\hat{x}_4 = (1/\sqrt{2} \ 1/\sqrt{2}) \begin{pmatrix} 4 \\ 3 \end{pmatrix} = \frac{7}{\sqrt{2}}$$



- 더 좋은 축이 있나?

그림 8.13 투영에 의해 2 차원 공간을 1 차원 공간으로 축소

주성분 분석 | 알고리즘과 응용

- 최적의 축을 찾아 보자.

- 투영된 점의 평균과 분산

$$\hat{x}_i, 1 \leq i \leq N \text{의 평균} \quad \bar{\hat{x}} = \frac{1}{N} \sum_{i=1}^N \hat{x}_i = \frac{1}{N} \sum_{i=1}^N \mathbf{u}^T \mathbf{s}_i = \mathbf{u}^T \left(\frac{1}{N} \sum_{i=1}^N \mathbf{s}_i \right) = \mathbf{u}^T \bar{\mathbf{s}} \quad (8.29)$$

$$\hat{x}_i, 1 \leq i \leq N \text{의 분산} \quad \hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (\hat{x}_i - \bar{\hat{x}})^2 = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}^T \mathbf{s}_i - \mathbf{u}^T \bar{\mathbf{s}})^2 \quad (8.30)$$

- 문제를 다시 쓰면,

- (8.30)의 분산 $\hat{\sigma}^2$ 을 최대화하는 \mathbf{u} 를 찾아라.
 - $\mathbf{u}^T \mathbf{u} = 1$ 이라는 조건을 만족하는 조건부 최적화 문제로 다시 쓰면,
 - L 은 라그랑제 함수, λ 는 라그랑제 승수

$$\bullet L(\mathbf{u}) = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}^T \mathbf{s}_i - \mathbf{u}^T \bar{\mathbf{s}})^2 + \lambda(1 - \mathbf{u}^T \mathbf{u}) \text{ 를 최대화하는 } \mathbf{u} \text{를 찾아라.} \quad (8.32)$$

주성분 분석 | 알고리즘과 응용

- 미분하고 수식 정리하면,
$$\begin{aligned}\partial L(\mathbf{u}) / \partial \mathbf{u} &= \partial \left(\frac{1}{N} \sum_{i=1}^N (\mathbf{u}^T \mathbf{s}_i - \mathbf{u}^T \bar{\mathbf{s}})^2 + \lambda (1 - \mathbf{u}^T \mathbf{u}) \right) / \partial \mathbf{u} \\ &= \frac{2}{N} \sum_{i=1}^N (\mathbf{u}^T \mathbf{s}_i - \mathbf{u}^T \bar{\mathbf{s}})(\mathbf{s}_i - \bar{\mathbf{s}}) - 2\lambda \mathbf{u} \\ &= 2\mathbf{u}^T \left(\frac{1}{N} \sum_{i=1}^N (\mathbf{s}_i - \bar{\mathbf{s}})(\mathbf{s}_i - \bar{\mathbf{s}}) \right) - 2\lambda \mathbf{u} \\ &= 2\mathbf{u}^T \Sigma - 2\lambda \mathbf{u} \\ &= 2\Sigma \mathbf{u} - 2\lambda \mathbf{u}\end{aligned}\end{math}$$
- 0으로 놓고 풀면,

$$\Sigma \mathbf{u} = \lambda \mathbf{u} \tag{8.33}$$

- (8.33)을 해석하면,
 - 훈련 집합의 공분산 행렬 Σ 를 구하고, 그것의 **고유 벡터**를 구하면 그것이 바로 최대 분산을 갖는 \mathbf{u} 가 됨



주성분 분석 | 알고리즘과 응용

- 예제) 최대 분산을 갖는 축

$X = \{(2,1)^T, (2,4)^T, (4,1)^T, (4,3)^T\}$ 훈련 집합

$$\Sigma = \begin{pmatrix} 1.000 & -0.250 \\ -0.250 & 1.688 \end{pmatrix} \text{ 공분산 행렬}$$

$\lambda_1 = 1.7688, \mathbf{u}_1^T = (-0.3092, 0.9510)$ 고유 벡터

$\lambda_2 = 0.9187, \mathbf{u}_2^T = (-0.9510, -0.3092)$

$\mathbf{u}_1^T = (-0.3092, 0.9510)$ 축으로 투영된 특징 벡터:

$$\hat{x}_1 = (-0.3092 \ 0.9510) \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 0.3326$$

$$\hat{x}_2 = (-0.3092 \ 0.9510) \begin{pmatrix} 2 \\ 4 \end{pmatrix} = 3.1856$$

$$\hat{x}_3 = (-0.3092 \ 0.9510) \begin{pmatrix} 4 \\ 1 \end{pmatrix} = -0.2858$$

$$\hat{x}_4 = (-0.3092 \ 0.9510) \begin{pmatrix} 4 \\ 3 \end{pmatrix} = 1.6162$$

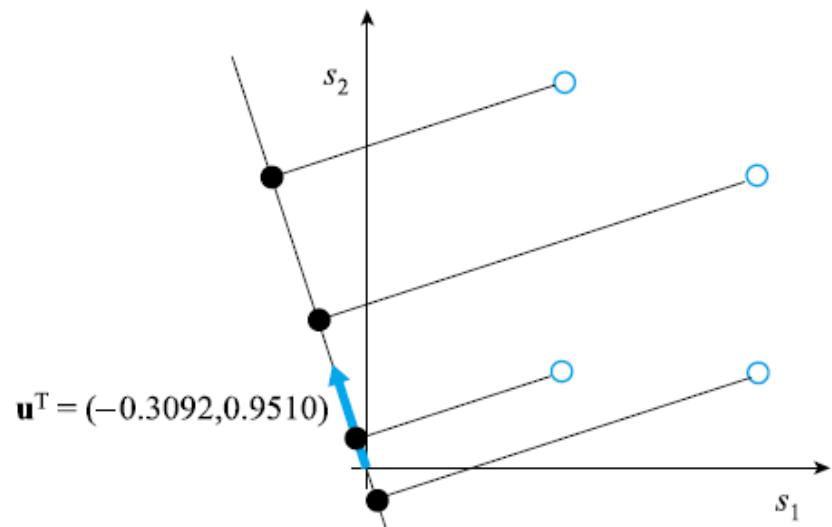


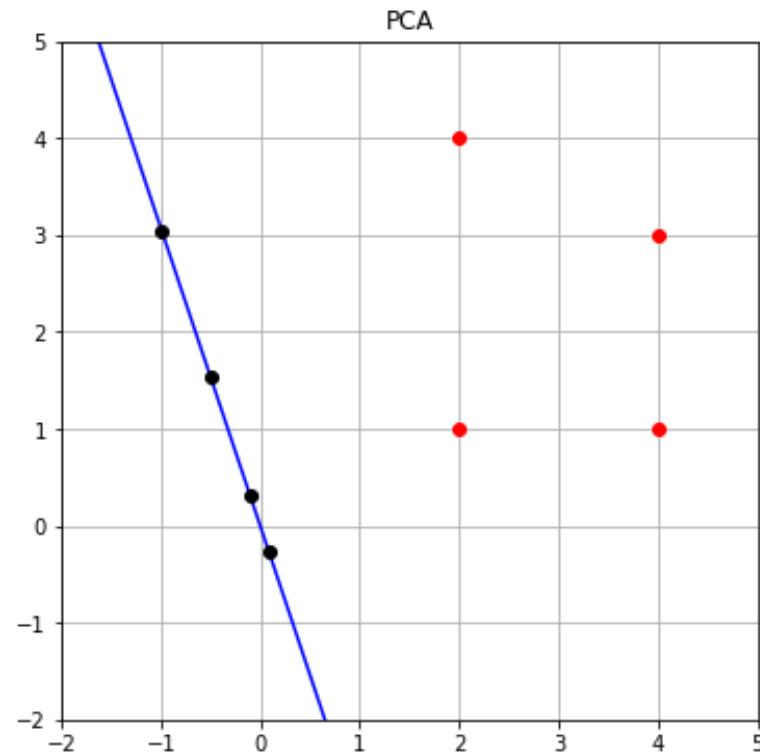
그림 8.14 PCA로 구한 최적의 축

이들의 분산은 1.7688
그림 8.13과 비교해 보자.

주성분 분석 | 알고리즘과 응용

- Python을 이용한 PCA
 - 최대 분산을 갖는 축

$$X = \{(2,1)^T, (2,4)^T, (4,1)^T, (4,3)^T\} \text{ 훈련 집합}$$



주성분 분석 | 알고리즘과 응용

- **변환 행렬**

- (8.33)을 풀면 D 개의 고유 벡터. 고유값이 큰 것일수록 중요도가 큼
- 따라서 D 차원을 d 차원으로 줄인다면 고유값이 큰 순으로 d 개의 고유 벡터를 취함. 이들을 주성분이라 부르고 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d$ 로 표기함
- 변환 행렬 \mathbf{U} 는,

$$\mathbf{U} = \begin{pmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_d^T \end{pmatrix} \quad (8.34)$$

- 실제 변환은,

$$\mathbf{x} = \mathbf{Us}$$

(8.35)



주성분 분석 | 알고리즘과 응용

알고리즘 [8.3]

PCA에 의한 변환 행렬 구함

- 알고리즘

입력: 훈련 집합 $X = \{s_1, s_2, \dots, s_N\}$, 원하는 차원 d

출력: 변환 행렬 U , 평균 벡터 \bar{s}

알고리즘:

1. $\bar{s} = \frac{1}{N} \sum_{i=1}^N s_i$ // X 의 평균 벡터
2. **for** ($i = 1$ **to** N) $s'_i = s_i - \bar{s}$; // 평균 벡터를 빼줌
3. $s'_i, 1 \leq i \leq N$ 의 공분산 행렬 Σ 를 구한다.
4. Σ 의 고유 벡터와 고유 값을 구한다.
5. 고유 값 기준으로 가장 큰 d 개의 고유 벡터를 선택한다.
이들을 u_1, u_2, \dots, u_d 라 하자.
6. (8.34)로 변환 행렬 U 를 만든다.
7. **return** U, \bar{s} ;

알고리즘 [8.4]

PCA에 의한 특징 추출

입력: 변환 행렬 U , 평균 벡터 \bar{s} , 샘플 s

출력: 특징 벡터 x

알고리즘:

1. $s = s - \bar{s}$; // 샘플에서 평균 벡터를 뺀다.
2. $x = Us$; // (8.35)
3. **return** x



예제

- 아래 훈련집합과 이를 기반으로 PCA 기법을 수행했을 때 두개의 고유 벡터 중에 고유 값이 작은 u_2 를 선택했을 때 투영된 특징 벡터들과 투영 변환된 점들의 분산을 구하고 고유 값이 큰 u_1 을 선택했을 때와 비교해보자. (Python을 이용해서 비교해보자.)
 - 훈련 집합: $X = \{(2,1)^T, (2,4)^T, (4,1)^T, (4,3)^T\}$

Fisher의 선형 분별

- Fisher의 선형 분별 linear discriminant (LD)
 - 특징 추출이 아니라 분류기 설계에 해당
 - 하지만 PCA와 원리가 비슷
 - PCA와 Fisher LD는 목표가 다름
 - PCA는 정보 손실 최소화 (샘플의 부류 정보 사용 안함)
 - Fisher LD는 **분별력을 최대화** (샘플의 부류 정보 사용함)

• 원리

- 축으로의 투영 $y = \mathbf{w}^T \mathbf{x}$
- 세 개의 축 중에 어느 것이 분별력 관점에서 가장 유리한가?

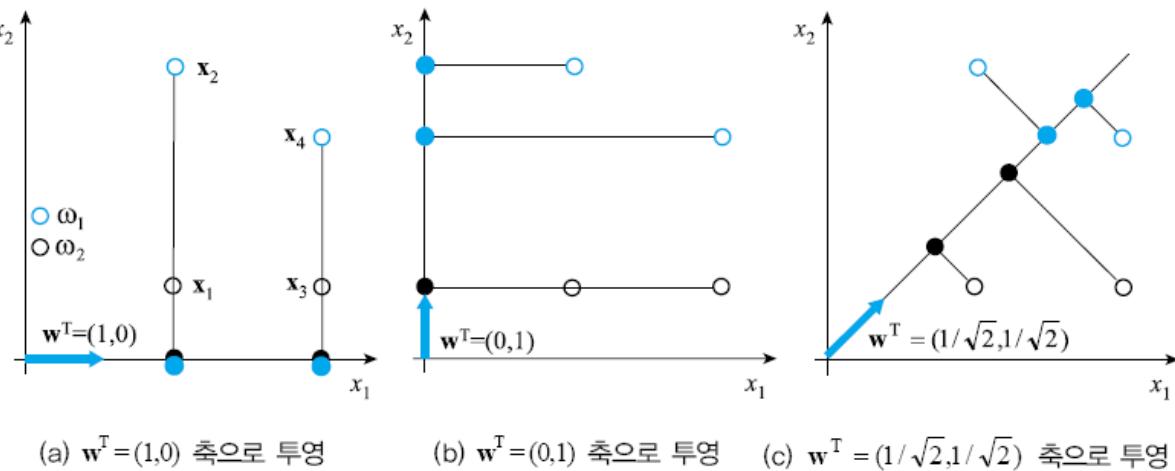


그림 8.15 2 차원 공간을 1 차원 공간으로 투영 (Fisher의 LD)

Fisher의 선형 분별

- 문제 공식화
 - 유리한 정도를 어떻게 수식화할까?
 - 가장 유리한 축 (즉 최적의 축)을 어떻게 찾을 것인가?
- 기본 아이디어
 - “같은 부류의 샘플은 모여있고 다른 부류의 샘플은 멀리 떨어져 있을수록 유리하다.”
 - 부류간 퍼짐 between-class scatter
 - 부류내 퍼짐 within-class scatter

$$\left. \begin{aligned} \mathbf{m}_i &= \frac{1}{N_i} \sum_{\mathbf{x} \in \omega_i} \mathbf{x} \\ \bar{m}_i &= \frac{1}{N_i} \sum_{y \in \omega_i} y \\ &= \frac{1}{N_i} \sum_{\mathbf{x} \in \omega_i} \mathbf{w}^T \mathbf{x} \\ &= \mathbf{w}^T \mathbf{m}_i \end{aligned} \right\}$$

부류간 퍼짐 = $|\bar{m}_1 - \bar{m}_2| = |\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2| = |\mathbf{w}^T (\mathbf{m}_1 - \mathbf{m}_2)|$

$$\bar{s}_i^2 = \sum_{y \in \omega_i} (y - \bar{m}_i)^2$$

부류내 퍼짐 = $\bar{s}_1^2 + \bar{s}_2^2$



Fisher의 선형 분별

- 목적 함수 $J(\mathbf{w})$

$$J(\mathbf{w}) = \frac{\text{부류간 페짐}}{\text{부류내 페짐}} = \frac{|\bar{\mathbf{m}}_1 - \bar{\mathbf{m}}_2|^2}{\bar{s}_1^2 + \bar{s}_2^2} \quad (8.43)$$

- $J(\mathbf{w})$ 를 최대화하는 \mathbf{w} 를 찾아라.
- 분자와 분모를 다시 쓰면,

분모

$$\begin{aligned} \bar{s}_1^2 + \bar{s}_2^2 &= \sum_{y \in \omega_1} (y - \bar{m}_1)^2 + \sum_{y \in \omega_2} (y - \bar{m}_2)^2 \\ &= \sum_{\mathbf{x} \in \omega_1} (\mathbf{w}^T \mathbf{x} - \mathbf{w}^T \mathbf{m}_1)^2 + \sum_{\mathbf{x} \in \omega_2} (\mathbf{w}^T \mathbf{x} - \mathbf{w}^T \mathbf{m}_2)^2 \\ &= \sum_{\mathbf{x} \in \omega_1} \mathbf{w}^T (\mathbf{x} - \mathbf{m}_1)(\mathbf{x} - \mathbf{m}_1)^T \mathbf{w} + \sum_{\mathbf{x} \in \omega_2} \mathbf{w}^T (\mathbf{x} - \mathbf{m}_2)(\mathbf{x} - \mathbf{m}_2)^T \mathbf{w} \\ &= \mathbf{w}^T \mathbf{S}_W \mathbf{w} \end{aligned}$$

분자

$$\begin{aligned} |\bar{\mathbf{m}}_1 - \bar{\mathbf{m}}_2|^2 &= (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2)^2 \\ &= \mathbf{w}^T (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w} \\ &= \mathbf{w}^T \mathbf{S}_B \mathbf{w} \end{aligned} \quad \left. \right\}$$

$$\circ] \text{ iff } \mathbf{S}_B = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T$$

$$\circ] \text{ iff } \mathbf{S}_W = \mathbf{S}_1 + \mathbf{S}_2 \circ] \text{ iff, } \mathbf{S}_i = \sum_{\mathbf{x} \in \omega_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T$$

Fisher의 선형 분별

- 목적 함수를 다시 쓰면,

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \quad (8.48)$$

- $\partial J(\mathbf{w}) / \partial \mathbf{w} = 0$ 으로 두고 풀면,

$$(\mathbf{w}^T \mathbf{S}_W \mathbf{w}) \mathbf{S}_B \mathbf{w} = (\mathbf{w}^T \mathbf{S}_B \mathbf{w}) \mathbf{S}_W \mathbf{w} \quad (8.49)$$

- (8.49)를 정리하면, $(\mathbf{w}^T \mathbf{S}_B \mathbf{w}) \mathbf{S}_W \mathbf{w} = (\mathbf{w}^T \mathbf{S}_W \mathbf{w}) \mathbf{S}_B \mathbf{w}$

$$(\mathbf{w}^T \mathbf{S}_B \mathbf{w}) \mathbf{S}_W \mathbf{w} = (\mathbf{w}^T \mathbf{S}_W \mathbf{w}) \alpha_1 (\mathbf{m}_1 - \mathbf{m}_2)$$

$$\mathbf{S}_W \mathbf{w} = \frac{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}{\mathbf{w}^T \mathbf{S}_B \mathbf{w}} \alpha_1 (\mathbf{m}_1 - \mathbf{m}_2)$$

$$\mathbf{S}_W \mathbf{w} = \alpha_2 \alpha_1 (\mathbf{m}_1 - \mathbf{m}_2)$$

$$\mathbf{w} = \alpha_2 \alpha_1 \mathbf{S}_W^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

- 결국 답은 (즉 구하고자 한 최적의 축은),

$$\mathbf{w} = \alpha \mathbf{S}_W^{-1} (\mathbf{m}_1 - \mathbf{m}_2) \quad (8.50)$$

Fisher의 선형 분별

- 예제 8.8 Fisher의 선형 분별

$$\mathbf{m}_1 = (3, 3.5)^T$$

$$\mathbf{m}_2 = (3, 1)^T$$

$$\mathbf{S}_W = \mathbf{S}_1 + \mathbf{S}_2 = \left[\begin{pmatrix} -1 \\ 0.5 \end{pmatrix} (-1 \ 0.5) + \begin{pmatrix} 1 \\ -0.5 \end{pmatrix} (1 \ -0.5) \right] + \left[\begin{pmatrix} -1 \\ 0 \end{pmatrix} (-1 \ 0) + \begin{pmatrix} 1 \\ 0 \end{pmatrix} (1 \ 0) \right] = \begin{pmatrix} 4 & -1 \\ -1 & 0.5 \end{pmatrix}$$

$$\mathbf{S}_W^{-1} = \begin{pmatrix} 0.5 & 1 \\ 1 & 4 \end{pmatrix}$$

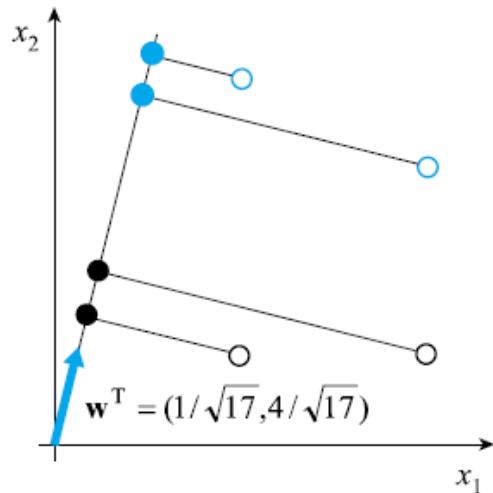


그림 8.16 Fisher의 선형 분별

ω_1 샘플 (파랑): $\mathbf{x}_2 = (2, 4)^T, \mathbf{x}_4 = (4, 3)^T$

ω_2 샘플 (검정): $\mathbf{x}_1 = (2, 1)^T, \mathbf{x}_3 = (4, 1)^T$

$$\mathbf{w} = \alpha \begin{pmatrix} 0.5 & 1 \\ 1 & 4 \end{pmatrix} \begin{pmatrix} 0 \\ 2.5 \end{pmatrix} = \alpha' \begin{pmatrix} 1 \\ 4 \end{pmatrix}$$

$$\mathbf{w} = \left(\frac{1}{\sqrt{17}}, \frac{4}{\sqrt{17}} \right)^T = (0.24254, 0.97014)^T$$

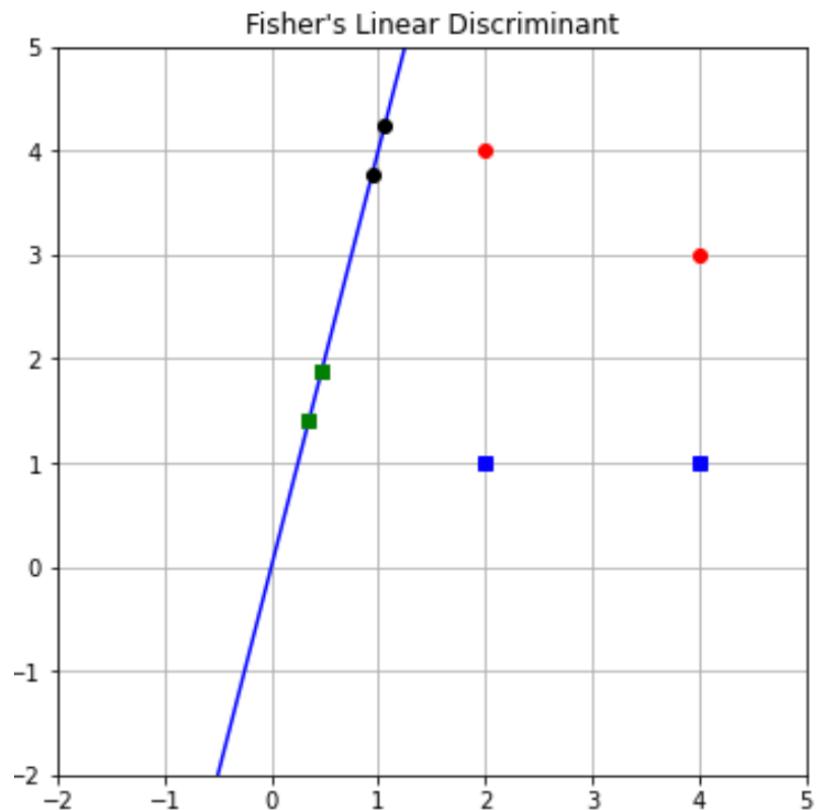
이것이 최적의 축이다.
그림 8.15 와 비교해
보자.

Fisher의 선형 분별 | Python 예제

- 예제 8.8 Fisher의 선형 분별

ω_1 샘플 (파랑): $\mathbf{x}_2 = (2, 4)^T$, $\mathbf{x}_4 = (4, 3)^T$

ω_2 샘플 (검정): $\mathbf{x}_1 = (2, 1)^T$, $\mathbf{x}_3 = (4, 1)^T$



실용적 관점

- 특징 추출은 기계학습 과정에서 휴리스틱한 경험과 실험에 따른 시행착오가 가장 많이 필요한 단계
 - 외부 환경에 영향을 가장 많이 받기 때문
 - 여기서 소개하는 몇가지 실용적 방법이 도움이 됨
 - 특징이 만족스러운 성능을 보이지 못하면?
 - 버리고 다른 특징을 채택
 - 또는 기존 특징에 새로운 특징을 추가하는 특징 결합
 - 특징이 거리 개념을 가지지 않으면?
 - 예) 혈액형을 나타내는 특징 $x \in \{A, B, O, AB\}$
 - 거리 개념이 없는 특징 x_i 가 n 개의 값을 갖는다면 x_i 를 $x_{i1}, x_{i2}, \dots, x_{in}$ 으로 확장
 - $x_{i1}, x_{i2}, \dots, x_{in}$ 중 하나만 1을 가지고 나머지는 0



실용적 관점

- 특징 추출은 기계학습 과정에서 휴리스틱한 경험과 실험에 따른 시행착오가 가장 많이 필요한 단계
 - 외부 환경에 영향을 가장 많이 받기 때문
 - 여기서 소개하는 몇가지 실용적 방법이 도움이 됨
 - 특징마다 동적 범위가 크게 다르면?
 - 특징 값의 정규화

» 선형 변환

$$\tilde{x}_i = low_i + \frac{high_i - low_i}{max_i - min_i} (x_i - min_i) \quad (8.51)$$

» 통계에 의한 변환 (평균은 0, 표준 편차는 1을 가지도록 정규화)

$$\tilde{x}_i = \frac{x_i - \bar{x}_i}{\sigma_i} \quad (8.52)$$



실용적 관점 | 특징 전처리

- 예제) 특징 정규화

- 사람을 키 (m 단위)와 몸무게 (kg 단위)의 두 개 특징으로 표현

$$\mathbf{a} = (1.60, 70.0)^T, \mathbf{b} = (1.65, 65.5)^T, \mathbf{c} = (1.95, 71.0)^T, \mathbf{d} = (1.68, 72.0)^T$$

- 거리 계산에 따르면 \mathbf{a} 는 \mathbf{b} 보다 \mathbf{c} 에 가깝다.
 - 몸무게의 동적 범위가 커서 거리 계산을 주도하기 때문

- (8.51)의 정규화 식을 유도하면,

$$\tilde{x}_1 = 0 + \frac{1-0}{1.95-1.60} (x_1 - 1.60) = \frac{1}{0.35} (x_1 - 1.60)$$

$$\tilde{x}_2 = 0 + \frac{1-0}{72.0-65.5} (x_2 - 65.5) = \frac{1}{6.5} (x_2 - 65.5)$$

- 정규화하고 거리를 계산해 보면,

$$\mathbf{a}' = (0, 0.692)^T, \mathbf{b}' = (0.143, 0)^T, \mathbf{c}' = (1, 0.846)^T, \mathbf{d}' = (0.229, 1)^T$$

$$dist(\mathbf{a}', \mathbf{b}') = \sqrt{(0-0.143)^2 + (0.692-0)^2} = 0.707$$

$$dist(\mathbf{a}', \mathbf{c}') = \sqrt{(0-1)^2 + (0.692-0.846)^2} = 1.012$$